

Pipeline Méthodologique — Prédiction de Churn

Maroc Telecom · Machine Learning · 6 Étapes Clés



Collecte et Compréhension des Données (Data Ingestion)

Étape 1

Action :

Import d'un jeu de données contenant les informations de **7 043 clients** de télécommunications.

- Comprendre les variables disponibles : Tenure, Services souscrits, Type de contrat, Coûts mensuels.
- Identifier la variable cible : la colonne **Churn** (Oui / Non).



Analyse Exploratoire des Données (EDA)

Étape 2

Action :

Analyse des tendances, distributions et corrélations entre les variables.

Constat majeur : déséquilibre de classe détecté — environ **74%** des clients restent, seulement **26%** partent.

- **Sélection de variables** : technique **SelectKBest** (test Chi-deux) pour ne conserver que les **10 variables les plus pertinentes**.
- Variables retenues : Type de Contrat, Ancienneté (Tenure), Sécurité en ligne, etc.



Préparation et Nettoyage des Données (Preprocessing)

Étape 3

Étape critique :

Garantit la qualité des prédictions. Trois opérations essentielles :

- **Nettoyage** : conversion des données textuelles en numériques (ex : TotalCharges qui contenait des espaces vides).
- **Encodage — Label Encoding** : transformation des variables catégorielles ("Month-to-month" → 0 ; "One year" → 1) pour que l'algorithme puisse les traiter.
- **Normalisation — Standard Scaling** : mise à l'échelle des données numériques (prix, ancienneté) pour qu'aucune variable n'écrase les autres par sa grandeur physique.



Gestion du Déséquilibre (Resampling avec SMOTEENN)

Étape 4

Pourquoi ?

Le modèle initial était performant pour prédire les clients qui restent, mais **médiocre pour ceux qui partent** — notre cible réelle.

- **SMOTE** : crée des clients synthétiques pour la classe minoritaire (ceux qui partent) afin d'équilibrer le dataset.
- **ENN** : nettoie les données en supprimant les exemples qui se chevauchent trop entre les deux classes.

Résultat : un jeu de données équilibré et propre, prêt pour l'entraînement.



Modélisation et Évaluation

Étape 5

Algorithmes testés :

Régression Logistique · Arbres de Décision · SVM · Gradient Boosting · **Random Forest**

Champion : **Random Forest** — précision ~93%, F1-Score ~94%, AUC-ROC 0.96.

- Robustesse face aux données bruitées et capacité à classer l'importance des variables.
- **Sauvegarde** : modèle et outils de transformation exportés en fichiers **.pkl** (pickle) pour réutilisation.



Développement de la Solution Web (Déploiement)

Étape 6

Interface :

Application **Flask (Python)** pour rendre le modèle accessible aux décideurs de Maroc Telecom.

- **Prédiction Unitaire** : formulaire interactif pour tester un client spécifique.
- **Analyse de Masse (Batch)** : import d'un fichier CSV complet pour obtenir les prédictions de centaines de clients en un clic, avec option de téléchargement des résultats.

Résumé en 3 Points Clés

1

Fiabilité

Données équilibrées via SMOTEENN pour ne pas ignorer les départs.

2

Performance

Meilleur algorithme sélectionné : Random Forest (93% précision, F1 94%).

3

Accessibilité

Interface Flask simple et professionnelle aux couleurs de Maroc Telecom.