

QUESTIONS — RÉPONSES JURY

Prédiction du Churn Client · Secteur des Télécommunications

Anas Haddou & Mohammed Amine Tayek | EMG Rabat | 2025–2026

Encadré par : Pr. Nouredine Mohtaram

Mode d'emploi : Ce document regroupe toutes les questions susceptibles d'être posées par le jury, organisées par thème. Chaque **Q** (rouge) contient la question, chaque **R** (vert) contient la réponse à donner, et les notes en italique sont des conseils de présentation. **Total : 34 questions couvrant 7 thèmes.**

SOMMAIRE

1.	ML & Modèles	8 questions
2.	Données & EDA	6 questions
3.	Évaluation	5 questions
4.	Technique & Code	5 questions
5.	Métier & Contexte	5 questions
6.	Déploiement & Web	2 questions
7.	Perspectives	3 questions

● ML & Modèles

#1

Q Pourquoi avez-vous choisi le Random Forest comme modèle final plutôt que le Gradient Boosting qui a des scores similaires ?

R Les deux modèles ont effectivement des performances proches. Nous avons retenu le Random Forest pour trois raisons : il est plus rapide à entraîner et à prédire, il est plus facile à interpréter grâce à l'importance des variables, et il est moins sensible au surapprentissage sans nécessiter un tuning fin. Le Gradient Boosting est séquentiel et plus difficile à déployer en production dans notre contexte.

■ Si le jury insiste, vous pouvez préciser que les deux sont valides et que le GBM serait une amélioration future.

#2

Q Qu'est-ce que le Random Forest exactement, et comment fonctionne le mécanisme de vote ?

R Le Random Forest est un ensemble d'arbres de décision construits en parallèle. Chaque arbre est entraîné sur un sous-échantillon aléatoire des données (bootstrap) et utilise un sous-ensemble aléatoire de variables à chaque nœud. Pour une prédiction, chaque arbre vote pour une classe (churn ou non). La classe majoritaire est retenue. Cette agrégation réduit la variance et l'overfitting par rapport à un arbre unique.

#3

Q C'est quoi le critère 'Gini' utilisé dans votre RandomForestClassifier ?

R Le critère de Gini mesure l'impureté d'un nœud. Il varie entre 0 (nœud pur) et 0.5 (nœud totalement mixte). À chaque division, l'arbre choisit la variable et le seuil qui minimisent l'impureté de Gini dans les nœuds fils. C'est l'alternative à l'entropie (information gain) — en pratique ils donnent des résultats très proches, mais Gini est légèrement plus rapide à calculer.

#4

Q Pourquoi la régression logistique est-elle utilisée comme 'baseline' ? Qu'est-ce que cela signifie ?

R Un modèle baseline est le point de référence minimal qu'un modèle plus complexe doit dépasser pour justifier sa complexité. La régression logistique est simple, rapide et interprétable. Si notre Random Forest n'avait pas fait mieux, cela aurait signifié que la complexité supplémentaire n'était pas justifiée. Ici, le RF dépasse clairement la baseline avec +5 points d'accuracy et +3 points de recall.

#5

Q Qu'est-ce que l'overfitting et comment le Random Forest le réduit-il ?

R L'overfitting (surapprentissage) est quand un modèle mémorise les données d'entraînement au lieu d'apprendre des patterns généralisables. Il performe très bien sur le train set mais mal sur de nouvelles données. Le Random Forest le réduit par deux mécanismes : le bagging (chaque arbre voit un sous-échantillon différent) et le choix aléatoire de variables à chaque nœud, ce qui force la diversité entre les arbres. La moyenne des prédictions lisse les erreurs individuelles.

#6

Q Avez-vous effectué une optimisation des hyperparamètres (GridSearch, RandomSearch) ?

R Nous avons fixé manuellement les hyperparamètres principaux : `n_estimators=120`, `max_depth=15`, `min_samples_leaf=10`, `min_samples_split=5`. Ces valeurs ont été choisies empiriquement après plusieurs essais. Une optimisation formelle via `GridSearchCV` ou `RandomizedSearchCV` est envisagée comme perspective d'amélioration pour pousser l'accuracy au-delà de 96%.

■ Reconnaître cette limite est une marque de maturité scientifique.

#7

Q Qu'est-ce que le Cohen's Kappa et pourquoi l'avez-vous utilisé ?

R Le Cohen's Kappa mesure l'accord entre les prédictions du modèle et les vraies valeurs, en tenant compte de la part d'accord due au hasard. Contrairement à l'accuracy seule, il est robuste face aux classes déséquilibrées. Notre Random Forest obtient un Kappa de 0.9179, ce qui est considéré comme un accord 'presque parfait' (> 0.80).

#8

Q Pourquoi les réseaux de neurones ont-ils été testés mais non retenus ?

R Les réseaux de neurones sont puissants sur de grands volumes de données non structurées comme les images ou le texte. Ici, avec 7000 lignes et des données tabulaires structurées, ils n'apportent pas de gain significatif. De plus, ils fonctionnent comme une boîte noire — difficile d'expliquer à un opérateur télécom pourquoi un client précis va cherner. Le Random Forest offre des performances équivalentes avec une bien meilleure interprétabilité.

● Données & EDA

#9

Q D'où provient votre dataset et est-il représentatif de la réalité marocaine ?

R Notre dataset provient de Kaggle (Telco Customer Churn Dataset). Il représente une entreprise de télécommunications américaine. Il n'est donc pas directement représentatif du contexte marocain (Maroc Telecom, Orange Maroc, etc.). Cependant, les comportements de churn — sensibilité au prix, type de contrat, qualité de service — sont des universaux du secteur télécom. Un déploiement réel nécessiterait des données Maroc Telecom pour calibrer le modèle localement.

■ Bonne réponse honnête qui montre que vous comprenez les limites du transfert de domaine.

#10

Q Pourquoi avez-vous supprimé les 11 lignes manquantes plutôt que de les imputer ?

R 11 lignes sur 7043 représentent seulement 0.15% du dataset — l'impact sur les performances est statistiquement négligeable. L'imputation (par la moyenne, médiane ou KNN) aurait introduit un biais artificiel dans TotalCharges, qui est une variable directement calculée à partir de MonthlyCharges × tenure. Pour des valeurs manquantes plus nombreuses, l'imputation aurait été préférable.

#11

Q Qu'est-ce que SMOTEENN et pourquoi était-il nécessaire ?

R SMOTEENN combine deux techniques. SMOTE (Synthetic Minority Over-sampling Technique) génère des exemples synthétiques de la classe minoritaire (les churners) en interpolant entre des exemples existants dans l'espace des features. ENN (Edited Nearest Neighbors) supprime ensuite les exemples ambigus ou bruités des deux classes. C'était nécessaire car dans notre dataset, environ 26% des clients churneront — une asymétrie qui pousse naïvement le modèle à prédire 'no churn' pour maximiser l'accuracy. SMOTEENN corrige cette tendance.

#12

Q Quelles variables sont les plus importantes pour prédire le churn selon votre modèle ?

R Le Random Forest nous fournit l'importance de chaque variable. Les plus déterminantes sont : la durée du contrat (tenure) — les clients récents churneront beaucoup plus, le type de contrat (mensuel vs annuel vs 2 ans) — les contrats courts ont un churn bien plus élevé, les charges mensuelles (MonthlyCharges) — les clients avec des factures élevées sont plus à risque, et le type de service internet (Fiber Optic montre un taux de churn plus élevé que DSL).

#13

Q Avez-vous vérifié les corrélations entre variables ? Y a-t-il de la multicolinéarité ?

R Oui, nous avons analysé les corrélations. TotalCharges est fortement corrélée avec tenure et MonthlyCharges (c'est logique : total = mensuel × durée). Pour la régression logistique, cette multicolinéarité pose problème. Pour le Random Forest, ce n'est pas critique car l'algorithme sélectionne aléatoirement les variables à chaque nœud, ce qui dilue naturellement l'effet de la multicolinéarité.

#14

Q Comment avez-vous encodé les variables catégorielles ?

R Nous avons utilisé le Label Encoding pour les variables binaires (Yes/No → 0/1) et le One-Hot Encoding pour les variables nominales à plusieurs modalités comme InternetService (DSL, Fiber optic, No) ou Contract (Month-to-month, One year, Two year). Cela évite d'introduire un ordre artificiel entre des catégories sans relation ordinale.

#15

Q Pourquoi privilégiez-vous le Recall plutôt que l'Accuracy dans votre contexte ?

R L'Accuracy mesure le taux global de bonnes prédictions, mais elle peut être trompeuse avec des classes déséquilibrées. Dans notre contexte métier, un faux négatif (prédire 'no churn' alors que le client va partir) est bien plus coûteux qu'un faux positif (cibler un client fidèle par erreur avec une offre de rétention). Le Recall mesure : parmi tous les clients qui vont churner, combien avons-nous détectés ? Notre RF obtient 97.17% — c'est la métrique la plus importante pour limiter les pertes.

■ *Citer un exemple concret : 'si on rate 100 clients qui vont partir à 50€/mois, c'est 5000€ perdus par mois'.*

#16

Q Qu'est-ce que l'AUC-ROC et comment l'interpréter ?

R L'AUC-ROC (Area Under the ROC Curve) mesure la capacité du modèle à distinguer les deux classes. La courbe ROC trace le taux de vrais positifs (recall) en fonction du taux de faux positifs pour différents seuils. Une AUC de 0.5 équivaut à un modèle aléatoire, 1.0 est parfait. Notre Random Forest obtient 0.9587, ce qui indique une excellente capacité discriminante.

#17

Q Qu'est-ce qu'un faux positif et un faux négatif dans votre contexte précis ?

R Un faux positif : le modèle prédit que le client va churner, mais il reste. Conséquence : l'opérateur lui envoie inutilement une offre de rétention — coût modéré. Un faux négatif : le modèle prédit que le client reste, mais il part. Conséquence : l'opérateur ne réagit pas, perd le client définitivement — coût élevé. Notre objectif est donc de minimiser les faux négatifs, d'où la priorité au Recall.

#18

Q Comment éviter le data leakage dans votre évaluation ?

R Le data leakage se produit quand des informations du jeu de test contaminent l'entraînement, donnant des résultats artificiellement optimistes. Nous l'avons évité en : (1) séparant strictement train/test avant tout preprocessing, (2) appliquant SMOTEENN uniquement sur le train set, jamais sur le test set, (3) réalisant la normalisation avec les statistiques du train set uniquement.

■ *Question technique avancée — bien la maîtriser.*

#19

Q Avez-vous utilisé la validation croisée (cross-validation) ?

R Pour cette version du projet, nous avons utilisé un split 80/20 simple. La validation croisée k-fold (typiquement k=5 ou 10) aurait donné une estimation plus robuste de la performance en moyennant les résultats sur plusieurs partitions. C'est une amélioration prévue dans les perspectives pour confirmer la stabilité du modèle.

● Technique & Code

#20

Q Quelles sont les bibliothèques Python utilisées et leur rôle respectif ?

R Pandas : manipulation et nettoyage des données (DataFrames). NumPy : calculs numériques et tableaux. Scikit-learn : implémentation des algorithmes ML (RandomForestClassifier, LogisticRegression, etc.) et métriques. Imbalanced-learn : SMOTEENN pour le rééquilibrage. Matplotlib et Seaborn : visualisation des données et des matrices de confusion.

#21

Q Que fait exactement la ligne '`pd.to_numeric(df[TotalCharges], errors=coerce)`' ?

R Cette commande tente de convertir la colonne TotalCharges du type 'object' (texte) en type numérique float. L'option `errors='coerce'` signifie que si une valeur ne peut pas être convertie (par exemple une chaîne vide ''), elle est transformée en NaN au lieu de lever une exception. Cela nous a permis d'identifier les 11 lignes problématiques, que nous avons ensuite supprimées.

#22

Q Comment avez-vous sauvegardé et chargé le modèle pour le déploiement web ?

R Nous avons utilisé la bibliothèque joblib (standard avec Scikit-learn) pour sérialiser le modèle entraîné dans un fichier .pkl (pickle). Lors d'une prédiction web, le serveur charge ce fichier en mémoire et l'applique directement aux nouvelles données sans réentraîner. C'est la méthode standard pour déployer des modèles Scikit-learn en production.

#23

Q Comment fonctionne techniquement votre interface web de prédiction ?

R Le backend est développé en Python (Flask ou Django). Il expose une API REST qui reçoit les caractéristiques d'un client en JSON, les préprocess de la même façon que lors de l'entraînement (encodage, normalisation), les passe au modèle chargé, et retourne la prédiction avec la probabilité. Le frontend (HTML/CSS/JavaScript) envoie les données du formulaire à cette API et affiche le résultat.

#24

Q Comment gérez-vous le preprocessing des nouvelles données en production pour qu'il soit identique à l'entraînement ?

R C'est un point critique. Nous sauvegardons, en plus du modèle, le LabelEncoder et le StandardScaler entraînés sur les données d'entraînement. Lors d'une prédiction en production, ces mêmes objets de preprocessing sont appliqués aux nouvelles données. Cela garantit la cohérence : les nouvelles données sont transformées dans le même espace que celui sur lequel le modèle a été entraîné.

● Métier & Contexte

#25

Q Qu'est-ce que le churn exactement et comment est-il défini dans votre dataset ?

R Le churn désigne la résiliation ou l'abandon d'un service par un client. Dans notre dataset, la variable 'Churn' est binaire : Yes (le client a résilié dans le mois) ou No (il est resté). C'est donc du churn dit 'historique' — on prédit si un client actuel va cherner, en se basant sur les patterns des clients passés ayant churné.

#26

Q Comment votre solution peut-elle concrètement aider Maroc Telecom à réduire son taux de churn ?

R Concrètement, chaque mois, l'opérateur exporte sa base clients, l'importe dans notre outil batch, et obtient une liste des clients à risque avec leur probabilité de churn. Les équipes commerciales peuvent alors cibler ces clients avec des offres personnalisées : réduction tarifaire, upgrade de forfait, appel de fidélisation. La priorité est donnée aux clients à haute valeur (charges mensuelles élevées) ET à haut risque de churn.

#27

Q Quel est le coût financier du churn pour un opérateur télécom ?

R Acquérir un nouveau client coûte en moyenne 5 à 7 fois plus cher que de retenir un client existant. Dans le secteur télécom marocain, le revenu mensuel moyen par client (ARPU) est estimé entre 50 et 150 DH. Si Maroc Telecom a, par exemple, 5 millions de clients avec un taux de churn de 2% par mois, cela représente 100 000 clients perdus par mois, soit des millions de dirhams de revenus perdus. Un outil de prédiction qui réduit ce taux même de 0.5% représente un gain économique très significatif.

#28

Q Le modèle prédit-il POURQUOI un client va partir ou seulement QUI va partir ?

R Notre modèle prédit QUI va partir (classification binaire). Pour comprendre POURQUOI, nous utilisons l'importance des variables du Random Forest, qui indique les features les plus déterminantes globalement. Pour une explication au niveau individuel (pourquoi CE client précis), il faudrait utiliser des techniques d'interprétabilité comme SHAP (SHapley Additive exPlanations) ou LIME. C'est explicitement mentionné dans nos perspectives d'amélioration.

■ Bonne réponse qui montre la connaissance des limites et de l'état de l'art.

#29

Q Est-ce qu'un taux de churn de 26% est élevé pour le secteur télécom ?

R Dans notre dataset, environ 26% des clients ont churné sur la période observée. Dans le secteur télécom mondial, les taux de churn annuels varient entre 20% et 40% selon les marchés et les régions. Pour le marché marocain, les taux peuvent varier selon la concurrence entre Maroc Telecom, Orange et Inwi. Un taux mensuel de 2-3% est considéré préoccupant — au-delà, la survie de l'opérateur est en jeu sans acquisition massive de nouveaux clients.

● Déploiement & Web

#30

Q Comment avez-vous déployé l'application web ? Quel stack technique ?

R L'application est déployée avec un backend Python (Flask) exposant des endpoints REST. Le frontend est développé en HTML/CSS/JavaScript avec des couleurs Maroc Telecom (rouge et blanc). Le modèle est chargé au démarrage du serveur via joblib. Pour la prédiction individuelle, les données du formulaire sont envoyées en AJAX, preprocessées et prédites instantanément. Pour le mode batch, un fichier CSV/Excel est parsé côté serveur, les prédictions sont calculées et exportées.

#31

Q Comment gérez-vous les erreurs ou les données invalides soumises par l'utilisateur dans l'interface ?

R Côté frontend, nous avons des validations de formulaire (champs obligatoires, types numériques). Côté backend, nous appliquons des vérifications des types et des plages de valeurs attendues. Si une valeur est manquante ou hors norme, l'API retourne un message d'erreur explicite plutôt que de retourner une prédiction non fiable. Pour le mode batch, les lignes invalides sont signalées dans le rapport d'export.

● Perspectives

#32

Q Comment amélioreriez-vous ce projet si vous aviez plus de temps ?

R Plusieurs améliorations sont envisagées : (1) Optimisation des hyperparamètres via GridSearchCV, (2) Ajout de SHAP pour l'interprétabilité individuelle, (3) Intégration de données plus riches (historique d'appels, réclamations, interactions CRM), (4) Mise en place d'un pipeline de réentraînement automatique pour détecter le data drift, (5) Déploiement cloud (Azure ou AWS) avec une API scalable, et (6) Tableau de bord en temps réel pour les équipes commerciales.

#33

Q Qu'est-ce que le concept de 'data drift' et est-ce un risque pour votre modèle ?

R Le data drift désigne l'évolution des distributions des données en production par rapport aux données d'entraînement. Par exemple, si Maroc Telecom lance une nouvelle offre, les comportements clients changent — le modèle entraîné sur d'anciennes données peut devenir obsolète. C'est un risque réel en production. La solution est de monitorer régulièrement les métriques du modèle et de le réentraîner périodiquement sur des données récentes.

#34

Q Pourquoi ne pas avoir utilisé XGBoost qui est souvent le meilleur pour les données tabulaires ?

R XGBoost est effectivement l'état de l'art pour les données tabulaires structurées. Nous avons testé le Gradient Boosting de Scikit-learn qui est une implémentation similaire, et ses résultats sont proches du Random Forest. XGBoost spécifiquement n'a pas été inclus dans ce projet mais constitue une perspective directe — combiné avec SHAP pour l'interprétabilité, il représenterait probablement le meilleur choix final.

■ *Montrer que vous connaissez l'état de l'art même si vous ne l'avez pas implémenté.*