

# ■ Questions & Réponses — Soutenance PFE

Système de Prédiction de Churn · Maroc Telecom

12 Questions Préparées

5 Thématiques Clés

Prêt pour la Soutenance

## 01 ■ Contexte & Problématique

### Q1 — Pourquoi le choix de la prédiction du "Churn" pour Maroc Telecom ?

Le secteur des télécoms est très concurrentiel. Acquérir un nouveau client coûte 5 à 25 fois plus cher que d'en fidéliser un existant. Prédire le Churn permet à Maroc Telecom d'agir **proactivement** (offres spéciales, remises) avant que le client ne parte.

### Q2 — Quelle est la valeur ajoutée de votre solution par rapport à une analyse statistique classique ?

Une analyse classique donne des tendances générales. Notre modèle de Machine Learning permet une prédiction **individuelle** et **préventive**. On ne regarde plus pourquoi les clients sont partis, on prédit qui va partir.

## 02 ■ Données & Préparation (EDA)

### Q3 — Votre dataset présentait un déséquilibre de classes (74% vs 26%). Pourquoi est-ce un problème ?

Un modèle entraîné sur des données déséquilibrées aura tendance à toujours prédire la classe majoritaire (Non-Churn). Il aurait une bonne précision globale mais échouerait totalement à détecter les vrais clients sur le départ, ce qui est pourtant l'objectif principal.

#### Q4 — Vous avez utilisé SMOTEENN. Pourquoi cette technique spécifique ?

Le SMOTEENN combine :

- **SMOTE** — suréchantillonnage de la classe minoritaire.
- **ENN** — nettoyage des voisins les plus proches (exemples ambigus aux frontières).

Cette combinaison permet non seulement d'équilibrer les classes, mais aussi de rendre le modèle plus robuste en supprimant les exemples ambigus.

#### Q5 — Quelles variables (features) ont le plus d'impact sur le Churn ?

D'après notre analyse, les trois facteurs les plus déterminants sont :

- **Type de Contrat** (Mois à mois) — clients sans engagement très exposés.
- **Tenure** (ancienneté) — plus elle est faible, plus le risque est élevé.
- **Charges Mensuelles** — corrélées positivement au taux de départ.

### 03 ■ Modélisation & Performance

#### Q6 — Pourquoi avoir choisi le Random Forest comme modèle final ?

Nous avons testé plusieurs algorithmes (Régression Logistique, Arbre de Décision, Gradient Boosting). Le **Random Forest** a offert le meilleur compromis :

- Précision de **93%** avec bonne généralisation.
- Gère très bien les relations non-linéaires.
- Moins sensible au surapprentissage (overfitting) que les arbres simples.

#### Q7 — Expliquez la différence entre la Précision et le Rappel (Recall). Lequel avez-vous privilégié ?

- **Précision** : Parmi ceux prédits "Churn", combien partent réellement ?
- **Rappel** : Parmi ceux qui partent réellement, combien en avons-nous détectés ?

Nous avons privilégié le **F1-Score (94%)** qui équilibre les deux. Cependant, le Rappel reste crucial : rater un client qui va partir coûte plus cher qu'envoyer une promo à quelqu'un qui serait resté.

#### Q8 — Qu'est-ce que l'AUC-ROC (0.96 dans votre cas) ?

C'est une mesure de la capacité du modèle à distinguer les deux classes. Un score de **0.96** est excellent (proche de 1), indiquant que notre modèle sépare très efficacement les clients fidèles des clients à risque.

## 04 ■ Implémentation Technique

### Q9 — Comment fonctionne votre interface web ?

Nous avons utilisé **Flask** (Python) pour le backend. L'utilisateur peut :

- Saisir les données d'un **client unique** via un formulaire.
- Importer un **fichier CSV** pour un traitement par lot (Batch).

Le modèle pré-entraîné (format **.pkl**) est chargé pour effectuer les prédictions en temps réel.

### Q10 — Comment avez-vous assuré la compatibilité des nouvelles données avec le modèle ?

Nous avons créé une fonction de prétraitement (**preprocess\_new\_data** dans **app.py**) qui applique exactement les mêmes transformations qu'à l'entraînement :

- **Label Encoding** — encodage des variables catégorielles.
- **StandardScaler** — normalisation, via les objets sauvegardés à l'entraînement.

## 05 ■ Perspectives & Conclusion

### Q11 — Quelles seraient les prochaines étapes pour améliorer ce projet ?

- Intégrer des **données en temps réel** (logs d'appels, consommation data récente).
- Utiliser des modèles plus complexes comme **XGBoost** ou du **Deep Learning**.
- Ajouter un **module de recommandation** pour suggérer l'offre de fidélisation la plus adaptée à chaque profil client.

### Q12 — Si vous deviez déployer ce modèle en production chez Maroc Telecom, quels seraient les défis ?

Le principal défi serait **l'intégration avec le CRM existant** de l'entreprise et la mise à jour régulière du modèle pour s'adapter aux changements de comportement des clients (saisonnalité, nouvelles offres concurrentes).