

SCRIPTS DE PRÉSENTATION

Prédiction du Churn Client dans le Secteur des Télécommunications

Anas Haddou & Mohammed Amine Tayek | EMG Rabat | 2025-2026

Mode d'emploi : Chaque bloc contient le texte à prononcer (en noir) et une note de mise en scène en italique gris.
Les blocs **bleus** = Amine | Les blocs **jaunes** = Anas.

■ PARTIE 1 — Mohammed Amine Tayek (Slides 1 à 4)

Slide 1 **Page de Titre**

Bonjour à tous. Je m'appelle Mohammed Amine Tayek, et je suis accompagné de mon binôme Anas Haddou. Nous avons l'honneur de vous présenter aujourd'hui notre projet de fin de module intitulé : « **Prédiction du Churn Client dans le Secteur des Télécommunications** », réalisé sous l'encadrement du Professeur Nouredine Mohtaram, dans le cadre de notre formation à l'École Marocaine d'Ingénierie — EMG Rabat. Ce projet est né d'une problématique concrète et d'actualité dans le secteur télécom. Commençons par vous expliquer pourquoi ce sujet nous a motivés.

👉 *Regarder le jury, sourire, ton assuré. Montrer la slide de titre avec la main.*

Slide 2 **Introduction du Projet**

Le secteur des télécommunications est extrêmement concurrentiel. Chaque opérateur cherche à fidéliser ses abonnés, car acquérir un nouveau client coûte bien plus cher que d'en retenir un. Le **churn** — c'est-à-dire la résiliation d'abonnement — représente une perte directe de revenus. Notre projet propose une solution basée sur l'**analyse de données** et le **machine learning** pour anticiper quels clients risquent de partir, afin de permettre des actions proactives de rétention. L'objectif final : améliorer la satisfaction client et donner un avantage compétitif aux opérateurs.

👉 *Insister sur les mots 'anticiper' et 'proactif'. Faire le lien naturel avec la slide suivante.*

Slide 3 **Problématique et Enjeux**

Pourquoi les clients partent-ils ? Notre analyse identifie trois grandes causes. D'abord, l'**insatisfaction client** : des problèmes de qualité de service, des prix jugés trop élevés. Ensuite, les **offres concurrentielles** : les autres opérateurs proposent des innovations ou des tarifs plus attractifs. Et enfin, le **manque de communication** : quand l'opérateur ne maintient pas un lien de confiance avec son abonné, celui-ci se sent abandonné et part. Ces trois facteurs se combinent souvent, ce qui rend la détection du churn encore plus complexe — d'où l'intérêt d'un modèle intelligent pour les identifier.

👉 Pointer les trois zones du diagramme Venn sur la slide. Prendre le temps sur chaque facteur.

Slide 4 **Objectifs Spécifiques**

Pour répondre à cette problématique, nous nous sommes fixé cinq objectifs précis. Premier objectif : **développer un modèle prédictif du churn** performant. Deuxième : **analyser les données clients** pour comprendre quels facteurs poussent au départ. Troisième : **détecter les clients à risque** avant qu'ils ne résilient. Quatrième : proposer des **stratégies de fidélisation ciblées** basées sur ces prédictions. Et cinquième : au final, améliorer à la fois la **satisfaction client** et la rentabilité de l'entreprise. Je laisse maintenant la parole à mon binôme Anas pour la partie technique.

👉 Marquer une légère pause entre chaque objectif. Transition claire vers Anas à la fin.

■ PARTIE 2 — Anas Haddou (Slides 5 à 18)

Slide 5 **Solution Proposée**

Bonjour à tous. Je suis Anas Haddou. Notre solution repose sur plusieurs algorithmes de machine learning que nous avons comparés : la **régression logistique** comme baseline, les **arbres de décision**, le **Random Forest**, et les **réseaux de neurones**. L'implémentation est faite en Python avec NumPy, Pandas, Scikit-learn, Matplotlib et Seaborn. Vous pouvez voir à gauche notre interface web de prédiction — en mode individuel et en mode batch CSV/Excel — développée avec les couleurs de Maroc Telecom.

👉 Désigner l'interface sur la slide. Mettre en valeur l'aspect déployé / opérationnel.

Slide 6 **Random Forest — Algorithme Clé**

Je vais vous présenter plus en détail le Random Forest, qui est l'algorithme que nous avons retenu. L'idée est simple mais puissante : plutôt que de construire un seul arbre de décision, on en construit plusieurs centaines — chacun entraîné sur un sous-échantillon aléatoire des données. Chaque arbre vote pour une classe, et c'est la **majorité** qui l'emporte — c'est l'agrégation. On utilise le Random Forest quand on a beaucoup de variables, des données complexes, et quand on veut un modèle robuste sans trop d'ajustement manuel. Il nous donne aussi l'**importance de chaque variable**, ce qui est très utile pour comprendre le churn.

👉 Pointer le schéma des arbres. Expliquer avec les mains : 'chaque arbre vote'.

Slide 7 **Analyse des Données — EDA**

Avant de modéliser, il faut bien connaître ses données. Notre dataset provient de Kaggle et contient les informations de **7 044 clients** réparties sur **21 colonnes**, dont la dernière est la variable cible : **Churn**. Vous pouvez voir à droite un aperçu du tableau — il inclut des données démographiques, le type de contrat, les services souscrits, et les montants facturés. La qualité et la diversité de ces données sont essentielles pour la performance du modèle.

👉 Montrer le tableau sur la slide. Bien prononcer '21 colonnes' et 'variable cible Churn'.

Slide 8 **Préparation et Nettoyage des Données**

La première étape de nettoyage a consisté à vérifier l'intégrité du dataset avec Pandas. Nous avons constaté que la colonne **TotalCharges** était de type 'object' au lieu de numérique — nous l'avons corrigé avec **pd.to_numeric** et l'option **errors='coerce'** pour gérer les valeurs invalides. Il y avait exactement **11 lignes** avec des valeurs manquantes, que nous avons supprimées — un impact négligeable sur 7 000 entrées.

👉 Pointer l'extrait de code à droite. Insister sur la rigueur du nettoyage.

Slide 9 **Gestion du Déséquilibre — SMOTEENN**

Un problème classique en prédiction de churn : les classes sont **déséquilibrées**. Dans notre dataset, les clients qui ne churneront pas sont bien plus nombreux. Pour corriger cela, nous avons appliqué la technique **SMOTEENN** — une combinaison de SMOTE, qui génère des exemples synthétiques de la classe minoritaire, et d'ENN, qui supprime les exemples bruités. Résultat : un meilleur **Recall** sur la classe churn, ce qui est l'essentiel dans notre cas.

👉 Expliquer simplement SMOTE : 'on crée de faux clients qui churneraient pour équilibrer l'apprentissage'.

Slide 10 **Modélisation**

Pour la modélisation, nous avons divisé le dataset en **80% entraînement** et **20% test**. Vous voyez à gauche le code du Random Forest : 120 estimateurs, critère Gini, profondeur maximale 15. Chaque modèle a été entraîné et évalué selon la même procédure, ce qui garantit une comparaison équitable entre eux.

👉 Pointer le bloc de code. Rester sobre, ne pas lire tout le code ligne par ligne.

Slide 11 **Analyse Comparative — Partie 1**

Voyons maintenant pourquoi nous avons testé ces algorithmes. La **Régression Logistique** est notre baseline : simple, rapide, interprétable — mais elle échoue sur les relations non-linéaires et est sensible aux outliers. Les **Arbres de Décision** sont faciles à visualiser et gèrent nativement les variables catégorielles, mais ils ont tendance à faire de l'**overfitting** et sont instables.

👉 Ton comparatif, pédagogique. Pas de jugement, juste les faits.

Slide 12 **Analyse Comparative — Partie 2**

Notre **choix final** s'est porté sur le **Random Forest** : excellente précision sur les données tabulaires, il réduit drastiquement l'overfitting, et fournit l'importance de chaque variable. Nous avons aussi testé les **Réseaux de Neurones** — puissants sur de grands volumes, mais ici ils se comportent comme une boîte noire, difficile à justifier auprès d'un opérateur télécom, et ils nécessitent plus de données et de puissance de calcul.

👉 Insister sur 'notre choix final'. Valoriser le raisonnement derrière la décision.

Slide 13 **Évaluation — Métriques**

Pour évaluer nos modèles, nous avons utilisé six métriques : l'**accuracy**, le **recall**, la **precision**, le **F1-score**, l'**AUC-ROC**, et le **Cohen's Kappa**. Nous avons aussi visualisé les **matrices de confusion** grâce à notre fonction confmatplot, qui nous montre clairement les vrais positifs, vrais négatifs, faux positifs et faux négatifs. Cette combinaison de métriques nous donne une vision complète et sans biais de la performance réelle.

👉 Prendre le temps d'expliquer le Recall : 'c'est la métrique la plus importante pour nous — mieux vaut alerter trop que pas assez'.

Slide 14 **Résultats et Performances**

Voici les résultats concrets. Le **Random Forest** obtient une accuracy de **95,9%**, un recall de 97,17%, une précision de 94,92%, un F1-score de 96,03%, et une AUC-ROC de 95,87% — le meilleur résultat parmi tous les modèles testés. Sur la matrice de confusion, on voit 575 vrais non-churners et 617 vrais churners correctement classés, avec seulement 18 faux négatifs — c'est-à-dire 18 clients à risque non détectés. Le GradientBoosting est légèrement proche, mais le Random Forest reste notre choix par sa robustesse et son interprétabilité.

👉 Pointer les chiffres dans le tableau. Valoriser les 97% de recall : 'on détecte 97 clients sur 100 qui allaient partir'.

Slide 15 **Démo — Interface Web**

Nous avons déployé notre modèle dans une **interface web** intuitive. En mode **individuel**, l'opérateur saisit les caractéristiques d'un client et obtient immédiatement une prédiction. Une **sidebar** propose 15 exemples du dataset pour tester l'outil en temps réel. En mode **batch**, on peut importer un fichier CSV ou Excel contenant plusieurs milliers de clients et exporter les résultats. Une page de documentation technique est également intégrée.

👉 Idéalement, montrer une démo en direct. Sinon, pointer les captures d'écran sur la slide.

Slide 16 **Discussion — Facteurs Déterminants**

Notre analyse identifie les principaux facteurs influençant le churn : la **durée du contrat** — les clients en mensuel churneront beaucoup plus que ceux en deux ans, le **type de service internet** — la fibre optique présente un taux de churn plus élevé, les **charges mensuelles**, les caractéristiques d'expérience client et les variables démographiques. Le modèle atteint une précision de 97%, avec un bon recall et une spécificité équilibrée, ce qui le rend exploitable directement en production.

👉 Montrer les deux graphiques sur la slide. Commenter le graphique 'Contract' et 'InternetService'.

Slide 17 **Limitations**

Notre travail présente bien sûr certaines limites. La première : la **qualité et la taille du dataset** — 7 000 clients c'est bien, mais un dataset réel Maroc Telecom en contiendrait des millions. Deuxième : le risque d'**overfitting**, même réduit par le Random Forest. Troisième : des **variables manquantes** comme les interactions avec le service client, les réclamations, ou des indicateurs économiques externes qui pourraient enrichir les prédictions.

👉 Être honnête sur les limites, c'est une marque de maturité. Transition naturelle vers la conclusion.

Slide 18 **Conclusion et Perspectives**

Pour conclure, ce projet démontre qu'il est tout à fait possible de prédire le churn avec une précision très élevée grâce au machine learning, même avec un dataset public. Notre modèle Random Forest est performant, déployable et interprétable. Les perspectives d'amélioration sont nombreuses : optimiser les hyperparamètres, enrichir les données, ajouter de l'interprétabilité avec SHAP, détecter le churn en **temps réel**, et évaluer l'efficacité des stratégies de rétention. Nous vous remercions pour votre attention et restons disponibles pour vos questions.

👉 *Finir sur une note positive et dynamique. Regarder le jury. Sourire.*